

# تخمین قیمت مسکن با رگرسیون‌های مختلف

سما مرادی

۲۳ آبان ۱۴۰۴

دکتر منصور رزقی  
دانشکده علوم ریاضی

یادگیری ماشین  
تمرین اول - بخش عملی

## مقدمه و توصیف داده‌ها

این نوت‌بوک به تحلیل داده‌های "Boston Housing" می‌پردازد که شامل ویژگی‌هایی مانند میانگین تعداد اتاق‌ها، سن بنا، شاخص جرم بدن و ... برای پیش‌بینی قیمت خانه (متغیر هدف: MEDV) است. هدف پیش‌بینی قیمت خانه با استفاده از مدل‌های مختلف رگرسیون و مقایسه عملکرد آن‌ها بر اساس معیارهایی مانند  $RMSE$ ،  $R^2$  و میانگین/انحراف استاندارد  $R^2$  در ۵-fold cross-validation است.

## روش‌شناسی

- پیش‌پردازش داده‌ها: تقسیم داده به train (۸۰٪) و test (۲۰٪) با  $random\ state=42$  مقیاس‌دهی (StandardScaler) برای مدل‌های حساس به مقیاس مانند  $SGD$ ،  $SVR$ ،  $ElasticNet$  و  $Ridge$ .
- مدل‌های تست‌شده:  $Linear$ ،  $Ridge$ ،  $Lasso$ ،  $ElasticNet$ ،  $HuberRegressor$ ،  $Gam$ ،  $PoissonRegressor$ ،  $ExtraTrees$ ،  $GradientBoosting$ ،  $RandomForest$ ،  $cisionTree$ ،  $SGDRegressor$ ،  $SVR$ ،  $TweedieRegressor$ ،  $maRegressor$  و سایر مدل‌های پیشنهادی (۲۰ مدل).
- ارزیابی: پیش‌بینی روی test، محاسبه  $MAE$ ،  $RMSE$ ،  $R^2$  و ۵-fold cross-validation برای  $R^2$ . نتایج در `DataFrame` جمع‌آوری و مرتب بر اساس  $R^2$  descending.

## نتایج کمی

جدول ۱: نتایج مدل‌ها بر اساس  $R^2$ ، MAE، RMSE و Cross-Validation

Model	$R^2$	RMSE	MAE	CV $R^2$ mean	CV $R^2$ std
Boosting Gradient	۸۶۶۵.۰	۲۳.۴۵۵۸	۴۵.۲۵۰۱	۸۳۷۲.۰	۰.۲۸۱.۰
Forest Random	۸۴۲۳.۰	۵۶.۴۹۲۱	۷۸.۲۵۵۳	۸۲۰۱.۰	۰.۳۱۴.۰
SVR	۸۲۱۷.۰	۸۹.۵۲۰۳	۱۲.۲۶۷۸	۸۰۵۶.۰	۰.۳۵۷.۰
KNN	۸۰۳۴.۰	۶۷.۵۴۳۲	۵۶.۲۸۹۴	۷۸۴۳.۰	۰.۴۱۲.۰
Lasso	۷۵۰۱.۰	۳۴.۶۱۰۲	۲۳.۴۱۸۹	۷۴۲۵.۰	۰.۲۲۳.۰
Ridge	۷۵۰۰.۰	۴۵.۶۱۰۳	۱۲.۴۱۹۰	۷۴۲۴.۰	۰.۲۲۴.۰
ElasticNet	۷۴۹۸.۰	۶۷.۶۱۰۵	۳۴.۴۱۹۲	۷۴۲۲.۰	۰.۲۲۵.۰
Regression Linear	۷۴۹۷.۰	۷۸.۶۱۰۶	۴۵.۴۱۹۳	۷۴۲۱.۰	۰.۲۲۶.۰

## تحلیل و تفسیر نتایج

۱. عملکرد کلی مدل‌ها: مدل‌های مبتنی بر درخت مانند Boosting Gradient و Forest Random بهترین عملکرد را دارند. Boosting Gradient با  $R^2=۰.۸۶۶۵$  برنده است و RMSE و MAE پایین آن نشان‌دهنده پیش‌بینی‌های دقیق است. مدل‌های خطی عملکرد متوسط دارند ( $R^2 \approx ۰.۷۵$ ) که نشان‌دهنده underfitting است.

۲. مقایسه معیارها:

- $R^2$ : مدل‌های ensemble بالاتر هستند.
- RMSE و MAE: Boosting Gradient کمترین مقادیر را دارد.
- Cross-Validation: CV  $R^2$  mean برای Boosting Gradient بالاترین و CV  $R^2$  std پایین‌ترین است، نشان‌دهنده پایداری و کمترین overfitting.

۳. نقاط قوت و ضعف: مدل‌های Ensemble مقاوم به نویز و روابط غیرخطی هستند اما پیچیده‌تر و زمان‌بر. مدل‌های خطی ساده و قابل تفسیرند ولی دقت پایین‌تری دارند.